

Actividad 6 – Calidad de Datos

Unidad 2 · Completitud, Consistencia y Exactitud

Marco teórico

Calidad de datos: consiste en que los datos sean adecuados para el uso que se le quiere dar (*fitness for purpose*). Un mismo dato puede ser suficiente para una operación rutinaria y a la vez insuficiente para un análisis estratégico o para entrenar un modelo.

La mala calidad es un **problema invisible**: una tabla puede abrirse sin errores, un dashboard puede verse bien, un modelo puede entrenarse sin problemas, pero el resultado ser incorrecto.

Las 3 dimensiones de calidad de datos

1. Completitud

Pregunta si el conjunto de datos contiene toda la información relevante, o si hay campos vacíos, nulos o registros incompletos.

- No es solo “contar las celdas vacías”, sino que importa dónde falta la información y su impacto.
- Que falte un teléfono secundario o la segunda dirección puede ser irrelevante, pero que falte el ID del cliente, la fecha o el monto de una venta afecta la trazabilidad y confiabilidad del análisis.

2. Consistencia

Examina si los valores se mantienen coherentes entre columnas, tablas, sistemas y distintos momentos.

- Ej: una misma región que aparezca como “Buenos Aires”, “Bs. As”, “BA”, o un canal que aparezca como “E-commerce”, “ecommerce” o “e Commerce”.
- Es dañina porque fragmenta el análisis sin ser evidente: un gráfico puede mostrar varias categorías que en realidad son la misma.
- También incluye reglas lógicas: una devolución con fecha anterior a la venta es una inconsistencia.

3. Exactitud

Consiste en si el dato es comprobablemente correcto y refleja la realidad.

- Un dato puede estar completo y ser consistente, pero ser falso. Ej: un monto con formato correcto pero mal cargado; una edad de 200 años.
 - Se verifica comparándolo con otra fuente confiable, una regla de negocio o el sentido del dominio.
-

Ejercicios prácticos

Ejercicio 1 – Empresa de logística

Una empresa de logística tiene esta tabla de envíos:

ID Envío	Fecha envío	Fecha entrega	Ciudad destino	Peso (kg)
E001	2026-03-01	2026-03-05	Córdoba	3.2
E002	2026-03-02	(vacío)	cordoba	2.8
E003	2026-03-10	2026-03-04	CBA	4.1
E004	2026-03-04	2026-03-06	Córdoba	-1.5

Para cada fila con problema, indicá qué dimensión de calidad (completitud, consistencia o exactitud) se está violando y por qué. (Puede haber más de una dimensión afectada por fila).

Mi respuesta:

Fila 2: falla la completitud, ya que no tiene la fecha de entrega, y también la consistencia, ya que la ciudad de destino está escrita como “cordoba” mientras que en la fila 1 y fila 4 está como “Córdoba”.

Fila 3: falla la consistencia, ya que la fecha de entrega es anterior a la fecha de envío, por lo que no es coherente. También falla la consistencia en la ciudad de destino, que figura como “CBA” y no respeta la coherencia con el resto de los registros.

Fila 4: falla la exactitud, ya que el peso en kilos aparece como negativo y no refleja la realidad.

Ejercicio 2 – Plataforma educativa

Una plataforma educativa detecta que el 40% de sus estudiantes no tiene cargada la fecha de nacimiento, y que el resto del dataset está completo y bien escrito. El equipo de datos decide entrenar igualmente un modelo de predicción de abandono usando “edad” como variable.

- a) ¿Qué dimensión de calidad está comprometida?
- b) ¿Qué riesgo concreto trae usar esa variable así como está para entrenar el modelo?

Mi respuesta:

a) La dimensión de completitud está comprometida, ya que el 40% de datos incompletos es un número elevado, sobre todo sabiendo que se entrenará un modelo.

b) Afecta los resultados que da el modelo, ya que al ser una variable numérica, si la falta de datos no es aleatoria (por ejemplo, si los estudiantes que abandonan temprano son los que menos cargan sus datos), completar con un promedio o eliminar esas filas introduciría un sesgo: el modelo aprendería de un patrón distorsionado entre la edad y el abandono, y perdería representatividad sobre una porción grande de la población.

Ejercicio 3 – Reporte de ventas por región

Un analista construye un reporte de ventas por región y nota que “Buenos Aires” aparece tres veces en el gráfico de barras, con distintos totales cada vez, aunque en la base solo debería haber una categoría “Buenos Aires”.

- a) ¿Qué dimensión de calidad está fallando?
- b) ¿Qué consecuencia tiene esto sobre la interpretación del gráfico final?

Mi respuesta:

- a)** La dimensión que falla es la de consistencia, ya que al estar trabajando en una sola región (“Buenos Aires”) debería aparecer solo una vez y no tres.
- b)** La consecuencia es la fragmentación del análisis, y que el total real de la región no se entienda bien.

Ejercicio 4 – Base de ventas (clientes y productos)

En una base de ventas aparecen estos registros:

- Cliente 1001: nombre completo vacío, DNI cargado, email cargado.
- Cliente 1002: fecha de nacimiento 15/08/2035.
- Cliente 1003: figura como “baja definitiva” en la tabla de clientes, pero tiene una compra registrada ayer.
- Producto P55: precio en la tabla de productos \$10.000, pero en la tabla de ventas aparece vendido a \$100 sin descuento registrado.

Clasificar cada problema como completitud, exactitud o consistencia, justificando por qué. En algunos casos puede haber discusión, pero hay que poder defender técnicamente la clasificación.

Mi respuesta:

- Cliente 1001:** problema de completitud, ya que el nombre, que es una columna importante, está vacío y afecta la trazabilidad y confiabilidad.
- Cliente 1002:** problema de exactitud, ya que alguien nacido en 2035 estando en el año 2026 no refleja la realidad y es erróneo.
- Cliente 1003:** problema de consistencia, ya que entre las tablas no es consistente que esté dado de baja pero pueda seguir comprando.
- Producto P55:** problema de consistencia, ya que su valor difiere entre las tablas y fragmenta el análisis; también de exactitud, ya que no refleja la realidad de un negocio una diferencia de \$10.000 a \$100.

Ejercicio 5 – Clínica médica

En una base de una clínica médica aparecen estos registros:

- Paciente 2001: tiene cargado nombre, DNI y obra social, pero el campo “teléfono de contacto” está vacío.
- Paciente 2002: figura con fecha de última consulta “22/04/2024”, pero en el sistema de turnos tiene un turno confirmado y asistido para el 10/07/2026.
- Paciente 2003: su historia clínica indica una altura de 2,45 metros.
- Paciente 2004: en la tabla de pacientes figura como “activo, obra social OSDE”, pero en la tabla de facturación aparece una atención reciente facturada como “particular, sin obra social”.

Clasificar cada registro como completitud, exactitud o consistencia, justificando técnicamente. Prestar atención a los casos donde puede haber más de una dimensión afectada.

Mi respuesta:

Paciente 2001: problema de completitud, ya que aunque tiene nombre, DNI y obra social, tiene vacío el teléfono de contacto, lo que afecta la trazabilidad.

Paciente 2002: problema de consistencia, ya que entre la tabla de consultas y el sistema de turnos difieren las fechas; también problema de exactitud, ya que la última consulta registrada (“22/04/2024”) no refleja la realidad.

Paciente 2003: problema de exactitud, ya que una altura de 2,45 m no es posible y no refleja la realidad.

Paciente 2004: problema de consistencia, ya que difieren los valores entre la tabla de pacientes y la tabla de facturación, lo que afecta el análisis.