

Actividad 7 – Clasificación y modelos predictivos

Unidad 3 · Naïve Bayes, KNN, Árboles de decisión y métricas

Ejercicio 1 – Matriz de confusión y métricas de evaluación

Una plataforma educativa utiliza un modelo de clasificación para anticipar qué estudiantes podrían abandonar una materia. La clase positiva es **Abandona**. Se obtuvieron los siguientes resultados sobre un conjunto de prueba:

Estudiante	Resultado real	Predicción del modelo
E001	Abandona	Abandona
E002	Abandona	No abandona
E003	No abandona	No abandona
E004	No abandona	Abandona
E005	No abandona	Abandona
E006	Abandona	No abandona
E007	Abandona	Abandona
E008	Abandona	Abandona
E009	No abandona	No abandona
E010	Abandona	No abandona
E011	No abandona	No abandona
E012	No abandona	No abandona
E013	Abandona	Abandona
E014	Abandona	Abandona
E015	No abandona	Abandona

Se pide:

- Identificar TP, TN, FP y FN.
- Armar la matriz de confusión.
- Calcular accuracy.
- Calcular precision.
- Calcular recall.
- Interpretar qué implica un falso negativo en este caso.
- Indicar si, para este problema, sería más importante priorizar precision o recall. Justificar.

Mi respuesta:

- a) TP: 5, TN: 5, FP: 3, FN: 2
- b) Matriz de confusión — Realmente positivo: TP=5, FN=2. Realmente negativo: FP=3, TN=5.
- c) Accuracy: $(5+5)/15 = 66,7\%$
- d) Precision: $5/(5+3) = 62,5\%$
- e) Recall: $5/(5+2) = 71,4\%$
- f) Un falso negativo implica un estudiante que realmente abandonó, pero el modelo predijo que no abandona.
- g) Para este problema es más importante priorizar recall, puesto que hay que priorizar no perder estudiantes, por lo que importa más esos que abandonaron y el modelo predijo que no lo iban a hacer.

Ejercicio 2 – K-Nearest Neighbour aplicado a abandono de clientes

Una empresa de telefonía quiere clasificar si un cliente nuevo podría abandonar el servicio, usando KNN con $K = 3$ y estas variables: reclamos últimos 3 meses, días desde el último uso, satisfacción (1-10).

Cliente nuevo: Reclamos = 3, Días sin uso = 14, Satisfacción = 4

Cliente	Reclamos	Días sin uso	Satisfacción	Abandona
C001	0	2	9	No
C002	4	18	3	Sí
C003	1	6	7	No
C004	3	12	5	Sí
C005	2	15	4	Sí

Se pide:

- a) Calcular la distancia euclidiana entre el cliente nuevo y cada histórico.
- b) Ordenar de menor a mayor distancia e identificar los 3 vecinos más cercanos.
- c) Clasificar al cliente nuevo según la mayoría de esos vecinos.
- d) ¿Por qué la escala de las variables podría afectar este resultado si, por ejemplo, agregáramos “facturación mensual” (valores entre 1.000 y 500.000) como cuarta variable?

Mi respuesta:

- a) Distancia con C001: 13,34 (No abandona). Distancia con C002: 4,24 (Abandona). Distancia con C003: 8,77 (No abandona). Distancia con C004: 2,23 (Abandona). Distancia con C005: 1,41 (Abandona).
- b) K=3 vecinos más cercanos: C005 (1,41, Abandona), C004 (2,23, Abandona), C002 (4,24, Abandona).
- c) Como los 3 vecinos más cercanos abandonan, el nuevo cliente abandonará.
- d) Afectaría el resultado porque esa variable dominaría el cálculo de la distancia euclidiana, por lo que el resultado estaría condicionado por la facturación, cuando no tendría que ser así.

Ejercicio 3 – Naïve Bayes con probabilidades condicionales

Una empresa de comercio electrónico desea predecir si un cliente abandonará la plataforma. Para ello utiliza un modelo Naïve Bayes. La clase positiva es Abandona.

La empresa cuenta con 50 clientes históricos: 20 abandonaron, 30 no abandonaron.

Se desea clasificar un cliente nuevo con las siguientes características: Baja satisfacción = Sí. Muchos reclamos = Sí. Pocas compras recientes = Sí.

Entre los clientes que abandonaron: 16 de 20 tenían baja satisfacción; 14 de 20 tenían muchos reclamos; 15 de 20 tenían pocas compras recientes.

Entre los clientes que no abandonaron: 6 de 30 tenían baja satisfacción; 5 de 30 tenían muchos reclamos; 9 de 30 tenían pocas compras recientes.

Se pide:

- a) Calcular $P(\text{Abandona})$.
- b) Calcular $P(\text{No abandona})$.
- c) Calcular $P(\text{Baja satisfacción} \mid \text{Abandona})$.
- d) Calcular $P(\text{Muchos reclamos} \mid \text{Abandona})$.
- e) Calcular $P(\text{Pocas compras recientes} \mid \text{Abandona})$.
- f) Calcular $P(\text{Baja satisfacción} \mid \text{No abandona})$.
- g) Calcular $P(\text{Muchos reclamos} \mid \text{No abandona})$.
- h) Calcular $P(\text{Pocas compras recientes} \mid \text{No abandona})$.
- i) Calcular el puntaje Naïve Bayes para la clase "Abandona".
- j) Calcular el puntaje Naïve Bayes para la clase "No abandona".
- k) Clasificar al cliente nuevo.
- l) Explicar qué significa que Naïve Bayes asuma independencia entre variables.

Mi respuesta:

- a) $P(\text{Abandona}) = 20/50 = 40\%$
- b) $P(\text{No abandona}) = 30/50 = 60\%$
- c) $P(\text{Baja satisfacción} \mid \text{Abandona}) = 16/20 = 80\%$
- d) $P(\text{Muchos reclamos} \mid \text{Abandona}) = 14/20 = 70\%$
- e) $P(\text{Pocas compras recientes} \mid \text{Abandona}) = 15/20 = 75\%$
- f) $P(\text{Baja satisfacción} \mid \text{No abandona}) = 6/30 = 20\%$
- g) $P(\text{Muchos reclamos} \mid \text{No abandona}) = 5/30 = 16,7\%$
- h) $P(\text{Pocas compras recientes} \mid \text{No abandona}) = 9/30 = 30\%$
- i) Puntaje Abandona = $0,40 \times 0,80 \times 0,70 \times 0,75 = 16,8\%$
- j) Puntaje No abandona = $0,60 \times 0,20 \times 0,167 \times 0,30 = 0,6\%$
- k) Suma de puntajes = 17,4%. Probabilidad normalizada de abandono: 96,5%. Probabilidad normalizada de no abandono: 3,44%. El cliente nuevo tiene 96,5% de probabilidad de abandonar → se clasifica como **Abandona**.
- l) Significa que las variables no están relacionadas entre sí, pero no es representativo de la realidad, ya que algunas variables, por ejemplo la baja satisfacción, pocas compras recientes y muchos reclamos, sí tenían algún tipo de relación con abandonar.

Ejercicio 4 – Árbol de decisión e interpretación de reglas

Una empresa de streaming utiliza el siguiente árbol de decisión para clasificar usuarios según riesgo de cancelación:

Primera pregunta: ¿Días sin uso > 10?

Si la respuesta es sí: ¿Satisfacción <= 5?

Si la respuesta es sí: Cancela.

Si la respuesta es no: No cancela.

Si la respuesta es no: ¿Reclamos >= 2?

Si la respuesta es sí: Cancela.

Si la respuesta es no: No cancela.

Usuario	Días sin uso	Satisfacción	Reclamos
U001	15	4	1
U002	8	7	3
U003	12	8	0
U004	3	9	0
U005	11	5	2
U006	9	6	1
U007	7	4	2

U008	20	6	4
------	----	---	---

Se pide:

- Clasificar cada usuario como "Cancela" o "No cancela".
- Escribir el camino lógico seguido para cada clasificación.
- Identificar una regla completa del árbol que lleve a la clase "Cancela".
- Identificar una regla completa del árbol que lleve a la clase "No cancela".
- Explicar una ventaja de los árboles de decisión frente a otros modelos de clasificación.
- Explicar qué riesgo aparece si el árbol se vuelve demasiado profundo.

Mi respuesta:

a) y b)

U001: ¿Días sin uso > 10? Sí → ¿Satisfacción <=5? Sí → **Cancela**.

U002: ¿Días sin uso > 10? No → ¿Reclamos >=2? Sí → **Cancela**.

U003: ¿Días sin uso > 10? Sí → ¿Satisfacción <=5? No → **No cancela**.

U004: ¿Días sin uso > 10? No → ¿Reclamos >=2? No → **No cancela**.

U005: ¿Días sin uso > 10? Sí → ¿Satisfacción <=5? Sí → **Cancela**.

U006: ¿Días sin uso > 10? No → ¿Reclamos >=2? No → **No cancela**.

U007: ¿Días sin uso > 10? No → ¿Reclamos >=2? Sí → **Cancela**.

U008: ¿Días sin uso > 10? Sí → ¿Satisfacción <=5? No → **No cancela**.

c) Cuando un usuario tiene más de 10 días sin uso y satisfacción menor o igual a 5.

d) Cuando un usuario tiene menos de 10 días sin uso y menos de 2 reclamos.

e) Son más fáciles de explicar que un cálculo probabilístico, ya que se tiene el camino lógico que llevó a tomar esa decisión.

f) Si se vuelve demasiado profundo, un riesgo es el overfitting, que consiste en que el modelo aprende de memoria los datos de entrenamiento y, cuando recibe datos nuevos, falla en clasificar.

Ejercicio 5 – Comparación de dos modelos de clasificación

Una empresa financiera utiliza modelos de clasificación para detectar operaciones sospechosas. La clase positiva es Fraude. Se probaron dos modelos sobre el mismo conjunto de 1.000 operaciones.

Modelo A: TP = 70, TN = 850, FP = 50, FN = 30

Modelo B: TP = 90, TN = 760, FP = 140, FN = 10

Se pide:

- Calcular accuracy del Modelo A.
- Calcular precision del Modelo A.
- Calcular recall del Modelo A.

- d) Calcular accuracy del Modelo B.
- e) Calcular precision del Modelo B.
- f) Calcular recall del Modelo B.
- g) Comparar ambos modelos.
- h) Indicar cuál modelo elegiría si la prioridad fuera detectar la mayor cantidad posible de fraudes.
- i) Indicar cuál modelo elegiría si la prioridad fuera reducir falsas alarmas.
- j) Explicar por qué accuracy puede ser una métrica insuficiente en problemas de fraude.

Mi respuesta:

a) Accuracy (Modelo A) = $(70+850)/1000 = 92\%$

b) Precision (Modelo A) = $70/(70+50) = 58,33\%$

c) Recall (Modelo A) = $70/(70+30) = 70\%$

d) Accuracy (Modelo B) = $(90+760)/1000 = 85\%$

e) Precision (Modelo B) = $90/(90+140) = 39,1\%$

f) Recall (Modelo B) = $90/(90+10) = 90\%$

g) El Modelo A dio un mayor accuracy (predijo correctamente más casos en total) y también dio mayor precision, por lo que genera menos falsas alarmas; pero dio menor recall que el Modelo B.

h) Si la prioridad es detectar la mayor cantidad de fraudes, elegiría el Modelo B, ya que al tener mayor recall significa que tuvo menos falsos negativos, lo que es importante para no dejar pasar operaciones sospechosas.

i) Si la prioridad es reducir falsas alarmas, utilizaría el Modelo A, ya que al tener una precision mayor tiene menor cantidad de falsos positivos.

j) Para problemas de fraude, que normalmente están desbalanceados (mayor cantidad de transacciones "normales"), el accuracy es insuficiente ya que solo mide qué tan bien predice en general, pero no tiene en cuenta los falsos negativos, que son justamente los que hay que tratar de evitar en un problema de fraude.